Statistiques descriptives

LMAFY1101

Anouar El Ghouch

LSBA, Université catholique de Louvain, Belgium

Plan

Vocabulaire de la méthodologie statistique

Données catégorielles ou quantitatives discrètes

Description des données numériques
- Visualiser la répartition/distribution des données
- Indicateurs de localisation
- Indicateurs de dispersion
- Relations entre deux variables numériques

Vocabulaire de la méthodologie statistique

La statistique est une discipline scientifique qui concerne les aspects suivants:

- Recueillir et organiser des données.
- Les décrire et les résumer à l'aide, par exemple, de graphiques.
- Les analyser avec le but d'en extraire le plus possible d'informations pertinentes.
- Interpréter et communiquer les résultats de cette analyse et développée des outils d'aider à la décision.

Les données étudiées peuvent être de toute nature, ce qui rend la statistique utile dans tous les champs disciplinaires et explique pourquoi elle est enseignée dans toutes les filières universitaires, de l'économie à la biologie en passant par la psychologie et les sciences mathématiques.

La statistique dans divers domaines

Donnons quelques exemples d'utilisation de la statistique dans divers domaines.

- Biologie, médecine : essais thérapeutiques, épidémiologie, dynamique des populations, analyse du génome, ...
- Sciences de l'ingénieur : contrôle de qualité, sureté de fonctionnement (fiabilité, disponibilité, sécurité,...), maîtrise des risques industriels, ...
- Physique, sciences de la terre : prévisions météorologiques, exploration pétrolière, mécanique statistique, théorie cinétique des gaz, ...
- Sciences humaines : enquêtes d'opinion, sondages, études de populations, ...

Si on omet la collecte et l'organisation des données, les méthodes statistiques se répartissent, principalement, en deux classes :

Statistique descriptive

La statistique descriptive a pour but de résumer l'information contenue dans les données de façon synthétique et efficace. Elle utilise pour cela des représentations de données sous forme de graphiques, de tableaux de synthèse et d'indicateurs numériques. Elle permet de dégager les caractéristiques essentielles et de suggérer des hypothèses pour une étude ultérieure plus sophistiquée.

Statistique inférentielle

La statistique inférentielle va au-delà de la simple description des données. Elle a pour but de tirer des conclusions et/ou faire des prévisions concernant le phénomène (la population) étudié à partir des observations (l'échantillon) récoltées. Il faut pour cela proposer des modèles probabilistes et savoir évaluer et gérer les risques d'erreurs.

Exemple: Ampoule

Voici les durées de vie (en jours) de 10 ampoules toutes fabriquées et exploitées à l'identique.

91.6 89.7 201.3 94.3 95.4 87.3 170.9 159.5 118.4 107.1

• On peut constater que ces mesures varient "considérablement". S'agit'il de variations qui sont dues purement au hasard ? Ou, au contraire, ce sont là des variations "pas normales". Des variations dues, par exemple, à des erreurs de mesures ou dues au fait qu'on a oublié de contrôler un (ou des) facteur(s) qui a une influence significative sur la durée de vie ?

• Comment peut-on quantifier la variation observée ? Aussi, y a-t-il des valeurs atypiques parmi ces mesures ? Comment les repérer facilement ? Pour répondre à ces questions, il suffit de faire une analyse descriptive des données.

• Au vu de ces observations, est-il raisonnable de supposer que la durée de vie moyenne d'une ampoule quelconque est inférieure à une valeur fixe, disons 95 ? Quelle est la probabilité pour qu'une ampoule tombe en panne avant une date t. Il s'agit ici d'un problème d'inférence.

Les données représentent la matière première sans laquelle aucune étude statistique n'est possible.

On obtient classiquement des données à partir de deux sources distinctes : les études observationnelles et les études expérimentales:

Étude observationnelle

Dans une étude observationnelle, on observe et on mesure des caractéristiques spécifiques sans intervention qui a pour but d'influencer ou modifier les sujets de l'étude.
Exemple: Sondage d'opinion ou enquête. Données récoltées dans la nature ou sur internet.

Étude expérimentale

Dans une étude expérimentale (ou interventionnelle), les individus sont exposés à un ou plusieurs facteurs fixés et contrôlés par l'expérimentateur et on passe ensuite à l'observation de leur effets sur les sujets de l'étude.
Exemple: Essai dans un laboratoire de recherche (clinique, physique ou chimique).

La première étape d'une étude statistique consiste à bien définir la population visée par l'étude, c.-à-d. l'ensemble d'objets ou d'individus sur lesquels l'information est recherchée.

Puis à planifier la récolte des données dans le but d'obtenir un échantillon, c.-à-d. un sous ensemble, représentative de la population.

Exemples de population

- La collection de tous les individus souffrant d'une certaine maladie (population tangible).
- La collection de toutes les mesures qui pourraient être faites dans certaines conditions expérimentales (population conceptuelle ou hypothétique).

L'échantillon doit être collectées, de façon appropriée, par tirage aléatoire. L'échantillonnage aléatoire donne à tous les individus une chance égale d'être choisie, éliminant (ou réduisant) ainsi le risque de biais de sélection (sous ou sur-représentativité de certaines catégories ou variétés).

Type de données

Lors de la création d'un plan de récolte de données, il est aussi nécessaire de déterminer le ou les caractères qu'on souhaite observer ou mesurer.

On distingue deux types de caractère: quantitatif et qualitatif.

Caractère quantitatif (appelé aussi variable)

Les valeurs possibles d'un caractère quantitatif sont des nombres. Il y a deux sous-types:

- Discret. C'est une variable à valeurs dans un ensemble fini ou dénombrable.
  Exemple: combien de frères avez-vous? Les valeurs possibles sont 0,1,2,...
- Continu. Les valeurs possibles peuvent être tout nombre réel dans un intervalle donné.
  Exemple: hauteur, durée de vie, vitesse.

Caractère qualitatif ou catégoriel.

Les valeurs possibles d'un caractère qualitatif ne sont pas des nombres. Ces varaibles expriment l'appartenance à une catégorie.
Exemple: couleur, sexe, catégorie socio-professionnelle, groupe sanguin.

Certains caractères catégoriels viennent dans un ordre naturel et sont donc appelés caractère ou variable ordinales.
Exemple: qualité de l'eau (mauvaise, moyenne, bonne, excellente).

Remarques

- Il faut distinguer le type d'un caractère de l'encodage utilisé pour l'enregistrer. Par exemple le sexe est un caractère catégoriel, mais elle peut être encodée sous forme d'une variable quantitative (1 pour femme et 2 pour homme, par exemple).
- L'encodage d'un caractère ne change en rien sa nature. Faire des calculs arithmétiques sur un caractère catégoriel (encodée sous forme numérique) n'a évidemment aucun sens.

Données catégorielles ou quantitatives discrètes

Voici les notes d'un test (en anglais) dans une petite classe de 10 élèves:

A, D, C, D, C, C, C, C, F et B.

- Tableau des effectifs ou fréquences absolues

```
> Grades <- c("A", "D", "C", "D", "C", "C", "C", "C", "F", "B")
```

```
> tGrad <- xtabs(~Grades)
> tGrad
```

A	B	C	D	F
1	1	5	2	1

Notez que nous affichons l'invite > pour chaque commande telle qu'elle apparaîtrait dans R, mais cette invite ne fait pas partie du code.

- Fréquence relative ou proportion = l'effectif / l'effectif total.

Peut aussi être exprimée sous forme de pourcentage ($\times 100$).

```
> tGrad/sum(tGrad)
```

A	B	C	D	F
0.1	0.1	0.5	0.2	0.1

```
> prop.table(tGrad)
```

A	B	C	D	F
0.1	0.1	0.5	0.2	0.1

- Diagramme en barres

```
> barplot(tGrad, xlab = "Grades", ylab = "Frequence")
```

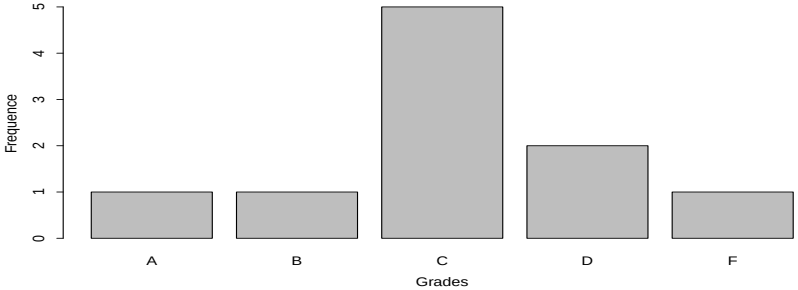

Exemple : Tabagisme

Les données utilisées pour cet exemple se trouvent dans le data.frame *Whickham* du package mosaicData, qui donne une petite partie d'une enquête menée à Whickham au Royaume-Uni au début des années 1970. On a demandé aux participantes (uniquement des femmes) leurs âges et si elles fumaient. Un suivi vingt ans plus tard a révélé si le participant était encore en vie.

Whickham contiennent 1314 observations et les variables suivantes :

- outcome : statut de survie après 20 ans: un facteur avec deux niveaux (Alive, Dead)
- smoker : statut de fumeur au départ: un facteur avec deux niveaux (No, Yes)
- age: âge (en années) au départ

Pour avoir plus d'information sur ces données, taper

```
> require(mosaicData)
> head(Whickham)
```

outcome	smoker	age
Alive	Yes	23
Alive	Yes	18
Dead	Yes	71
Alive	No	67
Alive	No	64
Alive	Yes	38

```
> str(Whickham)

'data.frame': 1314 obs. of  3 variables:
 $ outcome: Factor w/ 2 levels "Alive","Dead": 1 1 2 1 1 1 1 2 1 1 ...
 $ smoker : Factor w/ 2 levels "No","Yes": 2 2 2 1 1 2 2 1 1 1 ...
 $ age    : int  23 18 71 67 64 38 45 76 28 27 ...

> ## help(Whickham)
```

La distribution de la variable smoker

```
> Smo <- xtabs(~smoker, data = Whickham)
> Smo
```

No	Yes
732	582

```
> ProSmo <- prop.table(Smo)
> ProSmo
```

No	Yes
0.557	0.443

```
> barplot(ProSmo)
```

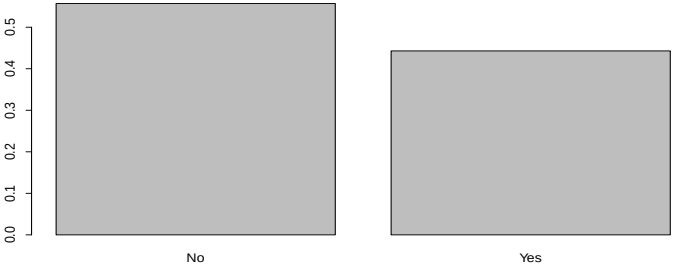

Relation entre deux variables catégorielles

- Pour croiser les différentes modalités de deux variables catégorielles, on utilse un tableau de contingence.
- C'est un tableau à deux entrées présente l'un des caractères en ligne et l'autre caractère en colonne.
- A l'intersection d'une ligne et d'une colonne on indique le nombre d'individus possédant simultanément ces deux valeurs de caractères.
- On complète généralement le tableau par une ligne et une colonne de totaux.

Table de contingence

Le contexte traité ici est celui où l'on étudie les deux variables catégoriques $X =$ smoker et $Y =$ outcome.

```
> SmoOut <- xtabs(~smoker + outcome, data = Whickham)
> SmoOut
```

	outcome	
smoker	Alive	Dead
No	502	230
Yes	443	139

```
> dSmoOut <- data.frame(SmoOut)
> dSmoOut
```

smoker	outcome	Freq
No	Alive	502
Yes	Alive	443
No	Dead	230
Yes	Dead	139

```
> addmargins(SmoOut)
```

Dans la ligne et la colonne «Sum» du tableau, on trouve les fréquences marginales de chacune des variables. Et le nombre total d'obs. $n = 1314$

	outcome		
smoker	Alive	Dead	Sum
No	502	230	732
Yes	443	139	582
Sum	945	369	1314

```
> PrjSmoOut <- prop.table(SmoOut)
> PrjSmoOut
```

Exemple d'interprétation: 38.2% de l'échantillon est constitué de femmes non fumeuses encore en vie 20 après le début de l'étude.

	outcome	
smoker	Alive	Dead
No	0.382	0.175
Yes	0.337	0.106

Fréquences conditionnelles: outcome|smoker

La variable *smoker* partage la population en deux groupes (fumeurs et non-fumeurs). Dans chacune de ces deux groupes, on s'intéresse à la distribution de la variable *outcome* (statut de survie).

```
> Pr1SmoOut <- prop.table(SmoOut, 1)
> Pr1SmoOut
```

	outcome		
smoker	Alive	Dead	Sum
No	0.686	0.314	1.000
Yes	0.761	0.239	1.000

Exemple d'interprétation: 68.6% des femmes non-fumeuses ont survécu 20 ans après.

Remarque. Pour calculer une fréquence conditionnelle $(A|B)$, on utilise la formule $\frac{\text{nbr. de sujets} \in (A,B)}{\text{nbr. de sujets} \in B}$

Diagramme en bâtons empilés

```
> barplot(t(Pr1SmoOut), legend = TRUE)
```

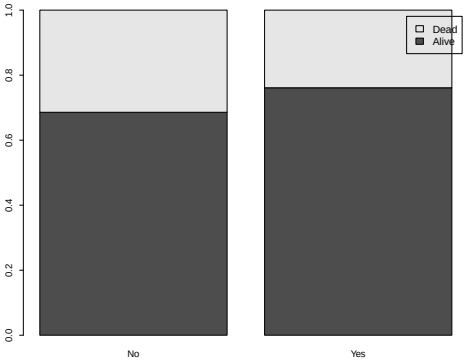

Diagramme en bâtons groupés

```
> barplot(t(Pr1SmoOut), legend = TRUE,
  beside = TRUE)
```

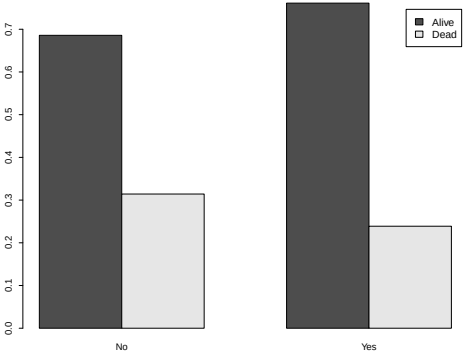

Diagramme en bâtons avec ggplot

```
> dPr1SmoOut <- data.frame(Pr1SmoOut)
> dPr1SmoOut

  smoker outcome  Freq
1     No   Alive 0.686
2    Yes   Alive 0.761
3     No    Dead 0.314
4    Yes    Dead 0.239
```

```
> ggplot(dPr1SmoOut) +
  aes(x=smoker, y=Freq, fill= outcome) +
  geom_bar(stat="identity", position = "dodge") +
  labs(y = "prop(outcome|smoker)")
```

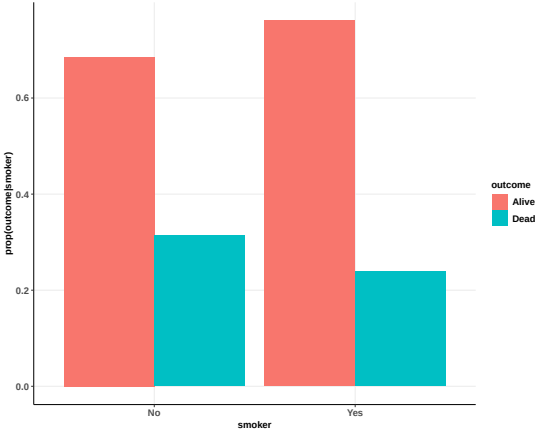

Cette analyse semble indiquer un effet “protecteur" du tabagisme: Seulement 69% des non-fumeuses ont survécu au bout de 20 ans contre 76% des fumeuses!

Est-ce que ceci peut être l’interprétation correcte?

Examinons les données en intégrant l’âge des femmes.

Pour cela, commençant par créer la variable $ageC$ qui contient trois modalités: "1" $= age \leqslant 24$, "2" $= 24 < age \leqslant 65$, "3" $= age > 65$.

```
> Whickham$ageC <- cut(Whickham$age, breaks = c(-Inf, 24, 65, Inf), labels = c("1",
      "2", "3"))
```

Table de contingence à trois variables

```
> SmoOutAge <- xtabs(~smoker + outcome + ageC, data = Whickham)
```

	ageC:	1		2		3	
smoker	outcome:	Alive	Dead	Alive	Dead	Alive	Dead
No		71	1	406	74	25	155
Yes		53	2	384	94	6	43

Distribution conditionnelle: outcome|(smoker,ageC)

```
> Pr13SmoOutAge <- prop.table(SmoOutAge, c(1, 3))
```

	ageC:	1		2		3	
smoker	outcome:	Alive	Dead	Alive	Dead	Alive	Dead
No		0.986	0.014	0.846	0.154	0.139	0.861
Yes		0.964	0.036	0.803	0.197	0.122	0.878

Visualisant ce tableau à l'aide d'un digramme en bâtons:

```
> dPr13SmoOutAge<- data.frame(Pr13SmoOutAge)
> ggplot(dPr13SmoOutAge) +
  aes(x=smoker, y=Freq, fill= outcome) +
  geom_bar(stat="identity", position = "dodge") +
  labs(y = "Prop(outcome|smoker, ageC)") +
  facet_grid(. ~ ageC)
```

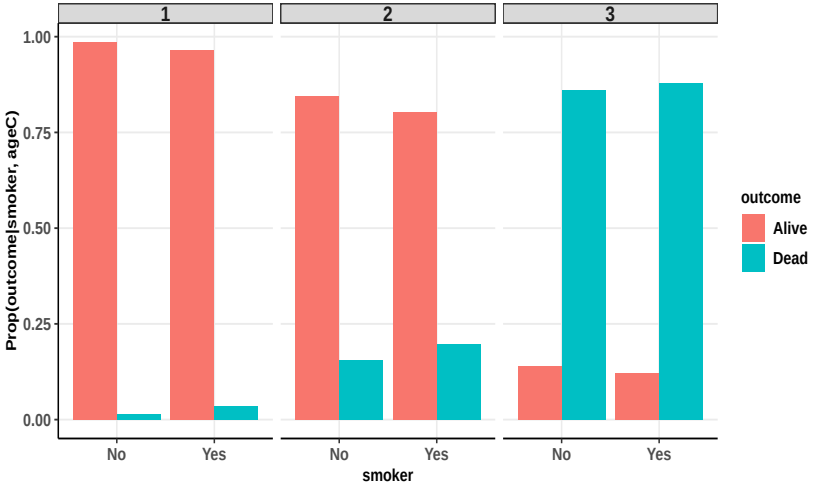

Dans chaque tranche d'âge, la survie chez les fumeuses est inférieure à celle des non-fumeuses.

Comment expliquer alors que la tendance s'inverse lorsqu'on mélange toutes les tranches d'âges?

Examinant la relation entre l'âge et les autres variables (outcome et smoker).

```
> AgeSmo <- xtabs(~ageC + smoker, data = Whickham)
> Pr1AgeSmo <- prop.table(AgeSmo, 1)
```

	smoker	
ageC	No	Yes
1	0.567	0.433
2	0.501	0.499
3	0.786	0.214

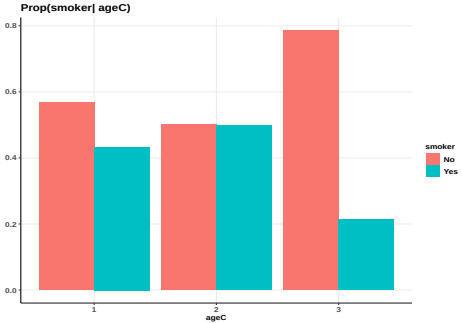


```
> AgeOut <- xtabs(~ageC + outcome, data = Whickham)
> Pr1AgeOut <- prop.table(AgeOut, 1)
```

	outcome	
ageC	Alive	Dead
1	0.976	0.024
2	0.825	0.175
3	0.135	0.865

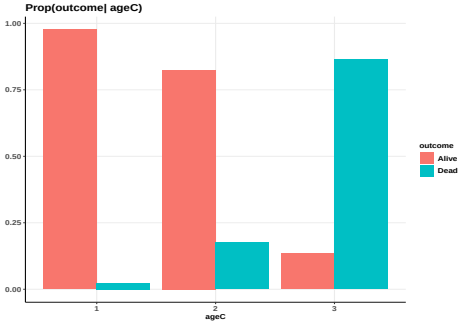

Peu de femmes âgées (plus de 65 ans lors de l'enquête initiale) étaient des fumeuses, mais beaucoup d'entre elles décèdent naturellement au bout de 20 ans. Ce qui a induit à l'effet "protecteur" du tabagisme observé lorsque l'âge a été ignoré.

Le fait d'ignorer une variable importante, ici l'âge, peut cacher ou inverser un effet ou une tendance. C'est une illustration de ce qui est connu sous le nom du paradoxe de Simpson.

Quand on vous présente des chiffres, il faut avoir l'œil et l'esprit bien critique!

Description des données numériques

Il y a beaucoup à dire sur les variables numériques, et de nombreux outils ont été développés pour les étudier.

Par la suite, nous allons étudier les éléments suivants:

- la répartition/distribution graphique des données
- les indicateurs dits de localisation
- les indicateurs dits de dispersion

Nous en apprendrons davantage sur ces termes au fur et à mesure.

Exemple: Qualité de l'air

Les données utilisées pour cet exemple donnent des informations sur la qualité de l'air à New York entre mai et septembre 1973. Une observation correspond à des mesures effectuées sur un jour de l'année. Voici les variables dans jeu de données :

- Ozone: Taux d'ozone (ppb)
- Solar.R : Radiation solaire (lang)
- Wind : Vitesse moyenne du vent (mph)
- Temp : Température quotidienne maximale (degrees F)
- Month : Mois (1-12)
- Day : Jours (1-31)

Il s'agit ici d'une étude observationnelle.

Pour avoir plus d'information sur ces données, taper

```
> head(airquality)
```

Ozone	Solar.R	Wind	Temp	Month	Day
41	190	7	67	5	1
36	118	8	72	5	2
12	149	13	74	5	3
18	313	12	62	5	4
NA	*NA*	14	56	5	5
28	*NA*	15	66	5	6

```
> str(airquality)

'data.frame': 153 obs. of  6 variables:
 $ Ozone  : int  41 36 12 18 NA 28 23 19 8 NA ...
 $ Solar.R: int  190 118 149 313 NA NA 299 99 19 194 ...
 $ Wind   : num  7.4 8 12.6 11.5 14.3 14.9 8.6 13.8 20.1 8.6 ...
 $ Temp   : int  67 72 74 62 56 66 65 59 61 69 ...
 $ Month  : int  5 5 5 5 5 5 5 5 5 5 ...
 $ Day    : int  1 2 3 4 5 6 7 8 9 10 ...

> ## help(airquality)
```

Avec de telles données, on peut être intéressé à étudier la distribution (les variations) dans les taux d'ozone, par exemple. Cette question porte sur une seul variable numérique. On parle alors d'une analyse univariée.

Une autre question d'intérêt est de décrire le lien entre, par exemple, le tau d'ozone et la température ou entre le tau d'ozone et et le mois. Ces questions portent sur deux variables (numérique-numérique ou numérique-factoriel). On parle alors d'une analyse bivariée.

Ces questions peuvent être explorés à la fois graphiquement et numériquement.

Commençant par transformer la variable *Month* en facteur:

```
> airquality <- transform(airquality, Month = factor(Month))
```

Description des données numériques

Visualiser la répartition/distribution des données

Diagramme en points : dotplot

```
> ggplot(data = airquality)+
  aes(x = "", y = Temp) +
  geom_point()
```

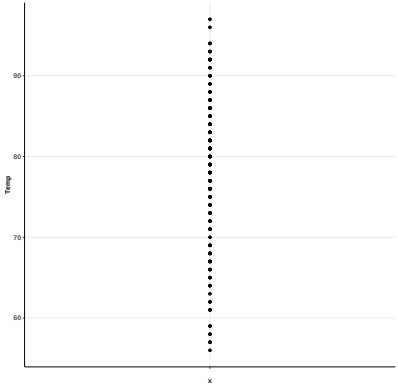


```
> ggplot(data = airquality)+
  aes(x = "", y = Temp) +
  geom_jitter(width = 0.25, height=0)
```

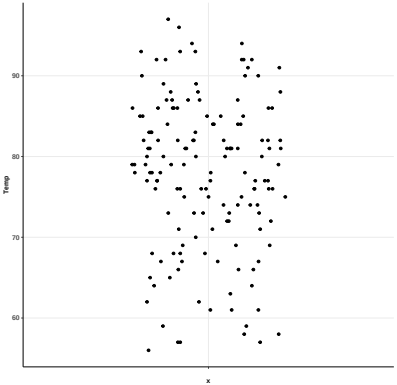

```
> ggplot(data = airquality) + aes(x = Month, y = Temp) +
  geom_jitter(width = 0.25, height=0)
```

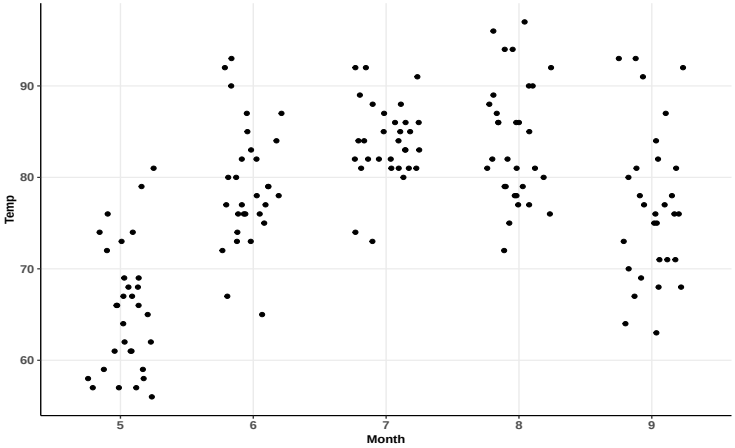

Histogramme

Lorsqu'on observe une série $x_1, \ldots, x_n$ de n observations issues d'une variable aléatoire continue, le moyen usuel de la représenter est l'histogramme qui consiste à (1) se fixer une origine $a_0 \leqslant \min_i x_i$, (2) se fixe une largeur de classe (binwidth) h, (3) regrouper les valeurs observées dans les classes (bins) $[a_0; a_0+h), [a_0+h; a_0+2h), \ldots$ et (4) construire un digramme en barres juxtaposées. La hauteur de la barre k est le nombre n_k d'observations se trouvant dans la classe k.

```
> ggplot(airquality) + aes(x = Temp) + geom_histogram()
```

```
`stat_bin()` using `bins = 30`.  Pick better value with `binwidth`.
```

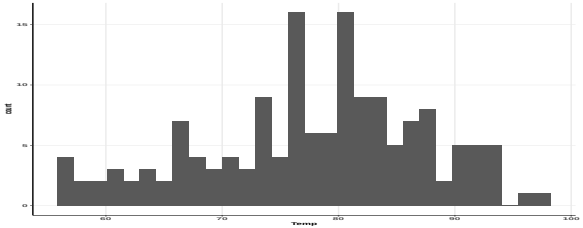

```
> ggplot(airquality) + aes(x = Temp) +
  geom_histogram(bins=30)
```

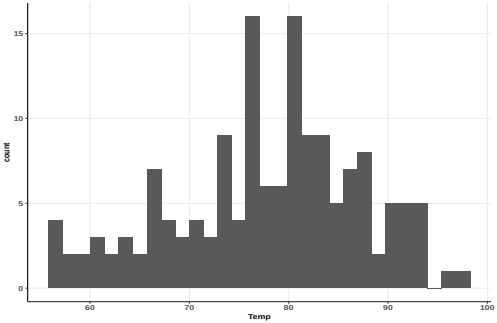


```
> ggplot(airquality) + aes(x = Temp) +
  geom_histogram(binwidth=1.4138)
```

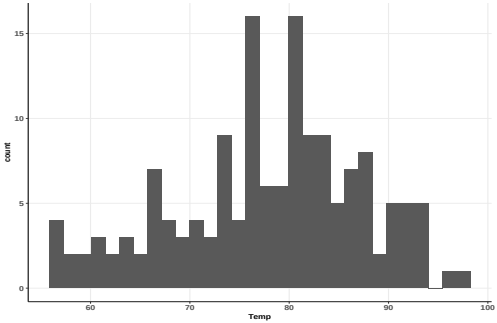

```
> ggplot(airquality) + aes(x = Temp) +
  geom_histogram(binwidth=6)
```

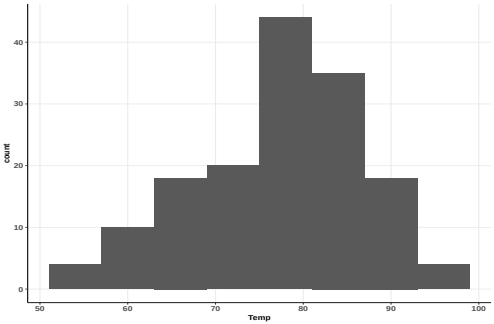


```
> ggplot(airquality) + aes(x = Temp) +
  geom_histogram(binwidth=12)
```

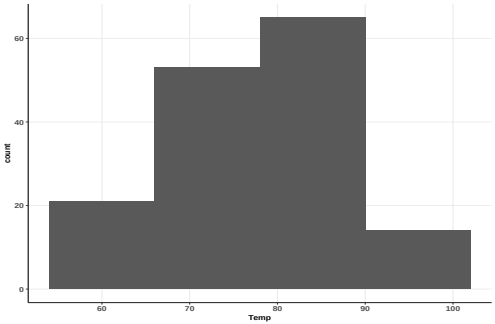

REMARQUE. Pour choisir une largeur de classe “optimale", on peut utiliser la fonction *dpih* du package *KernSmooth* :

```
> require(KernSmooth); dpih(airquality$Temp)

[1] 5.97
```

L'histogramme peut aussi être normalisé de telle façon que l'aire totale sous des rectangles vaut 1. Cette normalisation permet de comparer plus facilement deux (ou plusieurs) histogrammes ou un histogramme à une densité de probabilités théorique (qu'on définira plus tard).

La hauteur des rectangles d'un histogramme normalisé est donnée par: $\frac{n_k}{nh}$

```
> ggplot(airquality) + aes(x = Temp, y = ..density..) +
  geom_histogram(binwidth=6)
```

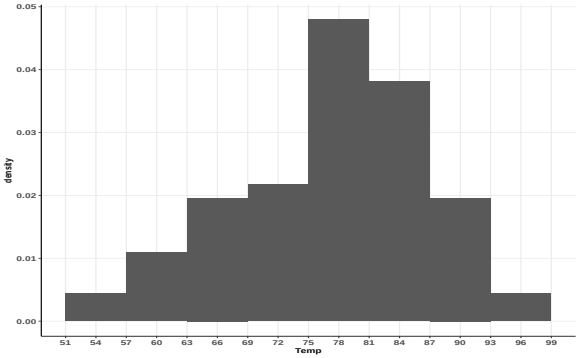

Afin de produire un graphique en panneaux par mois, nous ajoutons le facet_grid:

```
> ... + facet_grid(. ~ Month)
```

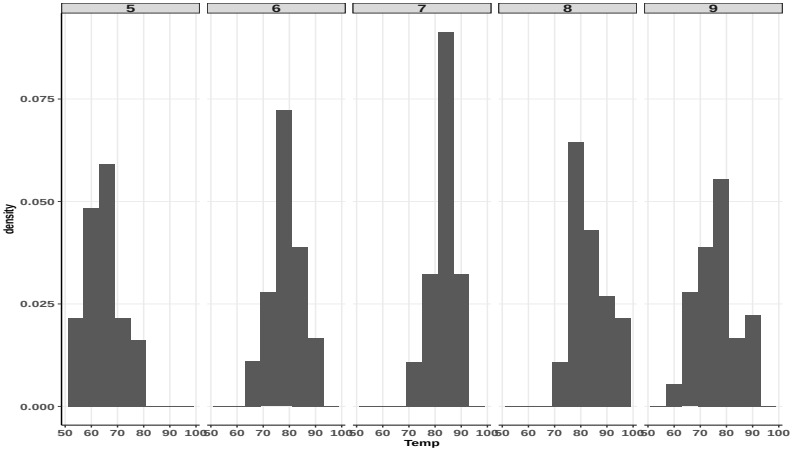

Une version plus lisse de l'histogramme, appelé polygone, est obtenue en joignant les points milieux des sommets de chaque barre.

```
> ggplot(airquality) +
  aes(x = Temp, y = ..density..) +
  geom_histogram(binwidth=6) +
  geom_freqpoly(binwidth=6)
```

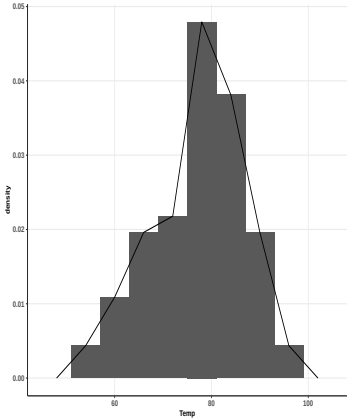


```
> ggplot(airquality) +
  aes(x = Temp, y = ..density..) +
  geom_freqpoly(binwidth=6)
```

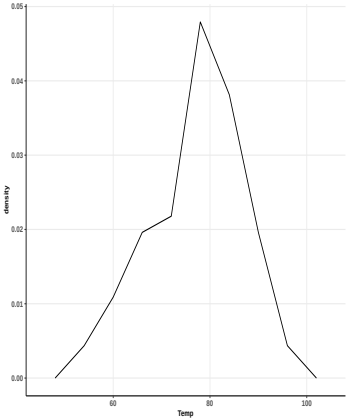

Pour avoir encore plus de lissage, il faut utiliser les courbes de densités qui sont esthétiquement plus attrayantes et plus utiles que les histogrammes et les polygones. Voici à quoi ressemble un graphe de densité de nos données:

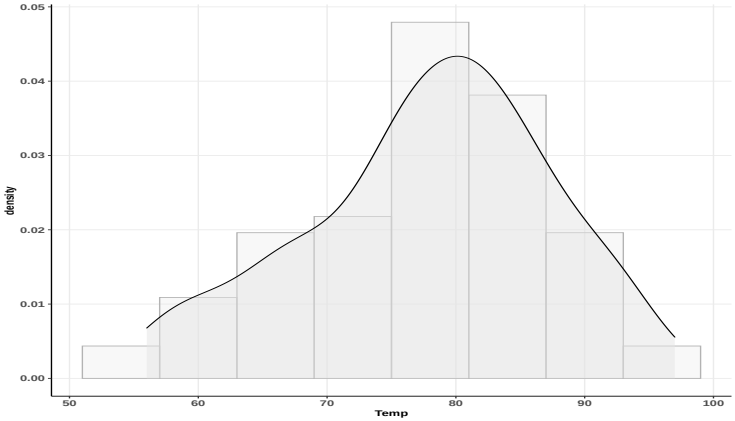

Pour comprendre les densités, nous devons comprendre d'abord les fonctions de densités de probabilités et leur estimation, un sujet que nous traiterons plus loin. Cependant, nous fournissons ici une explication heuristique pour comprendre les bases de cet outil de visualisation de données très utile.

Le concept principal est le suivant: nous supposons que nos observations proviennent d'une immense population. Dans notre cas, imaginez que, au lieu des 153 observations, nous disposant de 10^6 de prélèvements. Nous pouvons alors créer un histogramme avec de très très petites largeurs de classe h. Si nous faisons cela, les bars consécutifs seront très similaires et le polygone qu'on obtiendrait sera parfaitement lisse (sans discontinuité). C'est ce qu'on appellera, pour l'instant, la courbe de densité.

Cette idée est illustrée dans le slide suivant avec deux échantillons de 10^6 observations chacun.

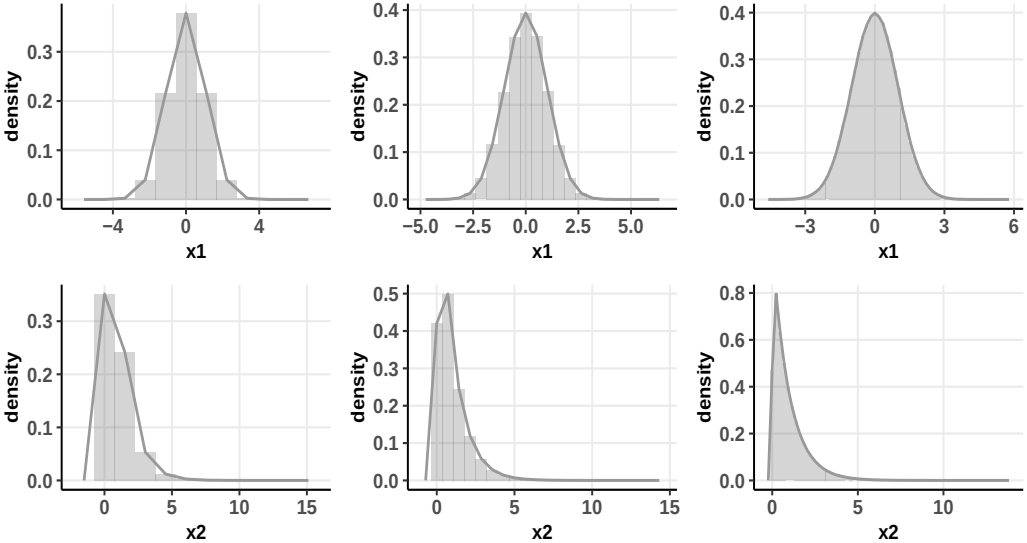

REMARQUE. Le nombre de barres de gauche à droite est de 10, 20 et 60 respectivement.

Les courbes de densité ne sont pas seulement pour des populations entières. Lorsque vous traitez avec des données d'échantillon, le diagramme de densité vous donne une estimation, basée sur votre échantillon, de ce à quoi la distribution de la population pourrait ressembler.

```
> ggplot(airquality) + aes(x = Temp, y = ..density..) + geom_density()
```

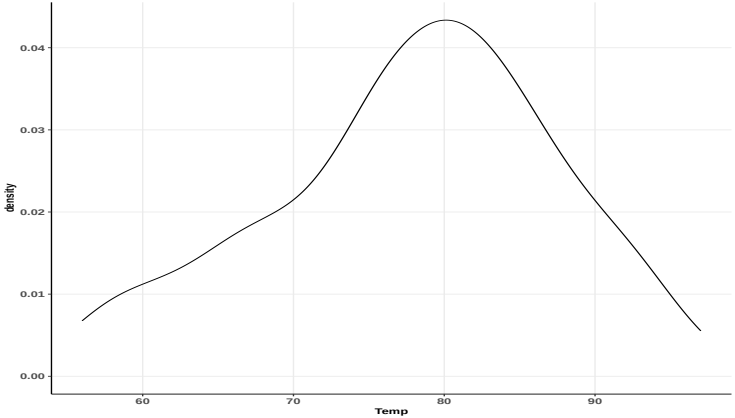

À l'aide d'un histogramme ou d'une courbe de densité, on peut décrire la forme globale de la distribution des données: symétrie/asymétrie, aplatissement, centre, dispersion,....

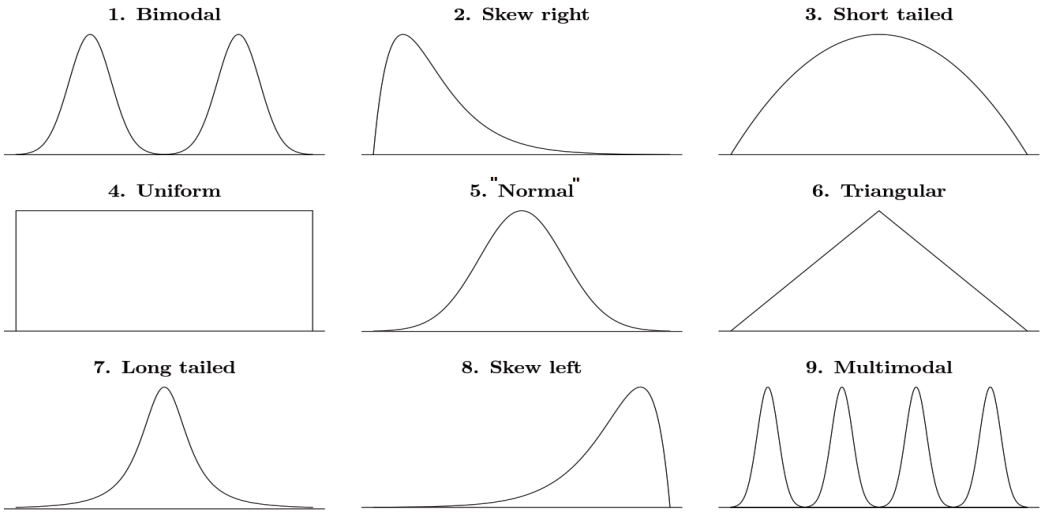

```
> ggplot(airquality) + aes(x = Temp) + geom_density() + facet_grid(. ~ Month)
```

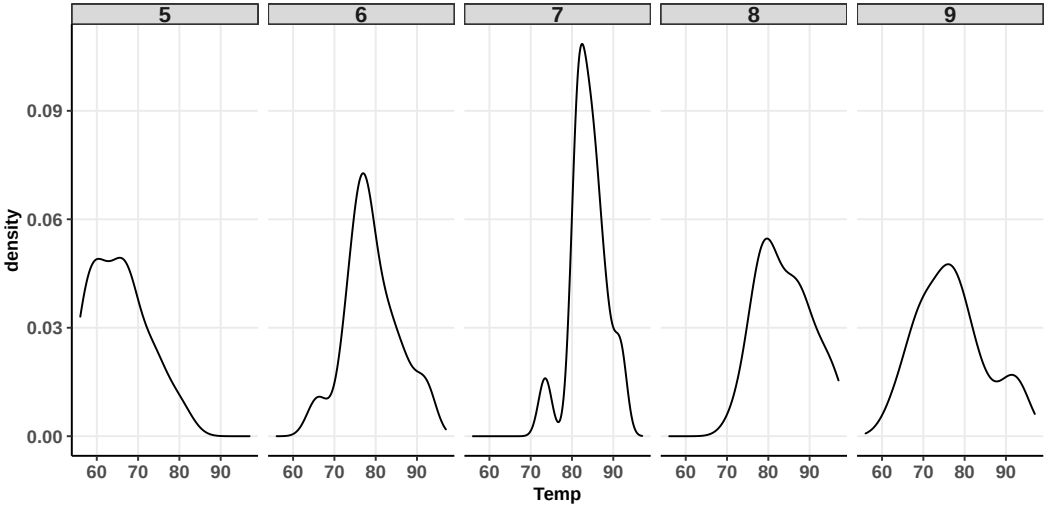

```
> ggplot(airquality) + aes(x = Temp, color=Month, fill=Month) +
  geom_density(alpha=0.1, size=1)
```

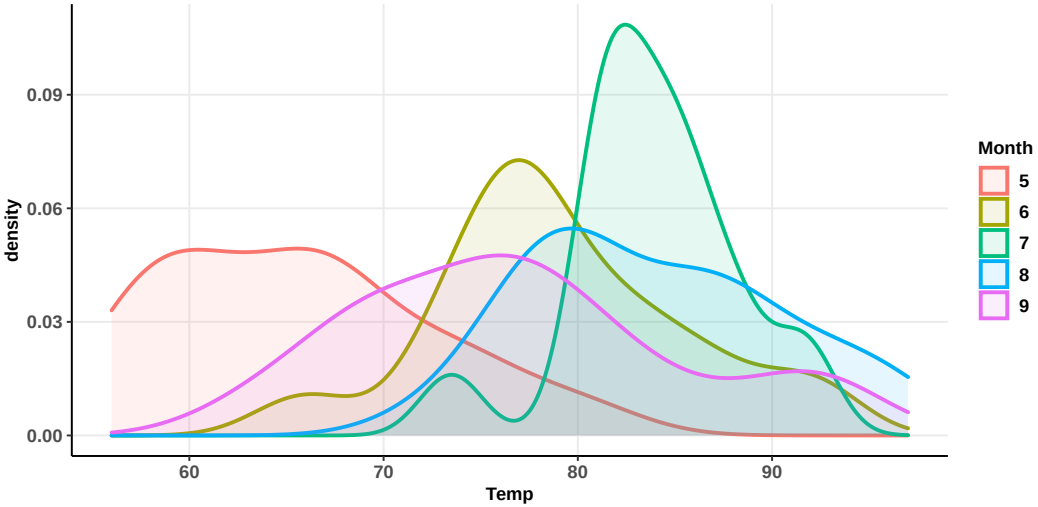

Description des données numériques

Indicateurs de localisation

Les indicateurs de localisation ainsi que ceux de dispersion (qu'on va voir par la suite) aident à caractériser les données et à décrire leurs spécificités.

Ces indicateurs peuvent s'appliquer à la population ou à l'échantillon.

Les résumés numériques de la population sont appelés paramètres, tandis que les résumés numériques de l'échantillon sont appelés statistiques ou mesures empiriques.

Des définitions plus formelles des paramètres qui caractérisent une population seront données ultérieurement.

Dans ce chapitre, on considère uniquement les mesures empiriques.

La MOYENNE EMPIRIQUE (mean en anglais) est la moyenne arithmétique des observations, notée par $\bar{x}_n$, est donnée par

$$\bar{x}_n = \frac{1}{n}\sum_{i=1}^{n} x_i$$

La moyenne empirique peut être interprété comme étant le centre de masse des observations ou leur point d'équilibre:

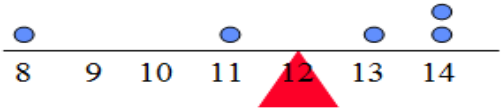


```
> mean(c(8, 11, 13, 14, 14))

[1] 12

> mean(c(8, 11, 13, 14))

[1] 11.5
```

La MÉDIANE EMPIRIQUE (median) est le nombre qui est juste au milieu (au sens proportionnelle) des données. Ce nombre sera notée par $q_{0.5}$

$q_{0.5}$ est telle que la moitié des observations lui sont inférieures et l'autre moitié lui sont supérieures.

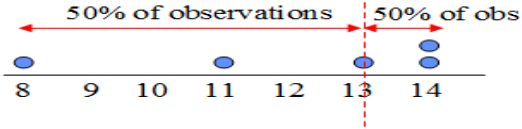


```
> median(c(8, 11, 13, 14, 14))
```

```
[1] 13
```

S'il y a un nombre pair d'observations, alors la médiane est la moyenne des deux points les plus proches du milieu.

```
> median(c(8, 11, 13, 14))
```

```
[1] 12
```

Moyenne ou Médiane ?

La moyenne se laisse influencer par les observations atypiques (outliers), qui peuvent être parfois erronées.

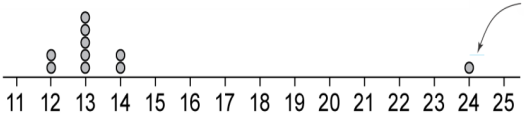

La médiane est plus résistante ou robuste que la moyenne.

```
> x <- c(12, 12, 13, 13, 13, 13, 13, 14, 14)
> y <- c(12, 12, 13, 13, 13, 13, 13, 14, 14, 24)
```

```
> mean(x)

[1] 13

> mean(y)

[1] 14.1
```

```
> median(x)

[1] 13

> median(y)

[1] 13
```

Moyenne, médiane et asymétrie

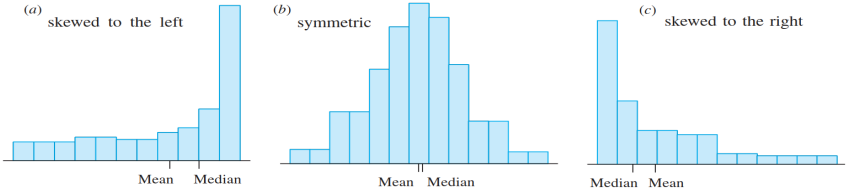

- Un histogramme ou une densité est symétrique si sa moitié droite est une image en miroir de sa moitié gauche, voire (b).
- Un histogramme asymétrique possède une queue plus longue que l'autre. Un histogramme avec une longue queue droite, voir (c), est dit asymétrique à droite, dans le cas contraire l'histogramme est dit asymétrique à gauche.
- Lorsque la distribution est parfaitement symétrique, la moyenne et la médiane seront identiques.
- Lorsque la distribution est asymétrique, la moyenne sera plus proche de la queue des données que la médiane.

Quantile empirique

Pour un $p \in (0,1)$ donné, le quantile empirique d'ordre p, noté q_p est la valeur qui partage l'échantillon en deux : une proportion p des observations sont inférieures à q_p et une proportion $1-p$ lui sont supérieures.

Pour calculer q_p, il faut d'abord ordonner les données du plus petit au plus grand. Si l'échantillon initial est noté $x_1, x_2, \ldots, x_n$ l'échantillon ordonné sera noté $x_{(1)}, x_{(2)} \ldots, x_{(n)}$, avec

$$x_{(1)} \leqslant x_{(2)} \leqslant \ldots, x_{(n)}$$

q_p est l'observation du rang $(1+(n-1)p)$

$$q_p = x_{(1+(n-1)p)}$$

Autrement dit, c'est l'observation qui occupe la place $(1+(n-1)p)$ dans l'échantillon ordonné.

Exemple

```
> x <- c(22.3, 17.9, 20.4, 24.6, 19.5, 26.2, 18.7)
> quantile(x, p = 0.3)

 30%
19.3
```

$q_{0.3}$ est la valeur qui correspond au rang $1 + (7 - 1) \times 0.3 = 2.8$. On peut la calculer, manuellement, par interpolation linéaire. Autrement dit, c'est la valeur situé à 80% du chemin entre $x_{(2)}$ et $x_{(3)}$.

$$\begin{aligned} q_{0.3} &= x_{(2)} + 0.8 \times (x_{(3)} - x_{(2)}) \\ &= 18.7 + 0.8 \times (19.5 - 18.7) = 19.34 \end{aligned}$$

Vous pouvez obtenir autant de quantiles que vous le souhaitez!

```
> quantile(x, p = c(0.25, 0.5, 0.75))

 25%  50%  75%
19.1 20.4 23.5
```

Certains quantiles ont des noms particuliers et des notations particulières. Les quantiles d'ordre 0.25, 0.50 et 0.75 sont également appelésle premier quartile, le deuxième quartile (ou médiane) et le troisième quartile et sont souvent dénotés Q_1, Q_2 et Q_3.

Le résumé à cinq nombres

Le vecteur $(x_{(1)}, Q_1, Q_2, Q_3, x_{(n)})$ est souvent appelé le résumé à cinq nombres. $x_{(1)}$ est simplement la plus petite observation et est souvent dénotée min (pour minimum). De même $x_{(n)}$, est simplement la plus grande observation et est souvent dénotée max (pour maximum).

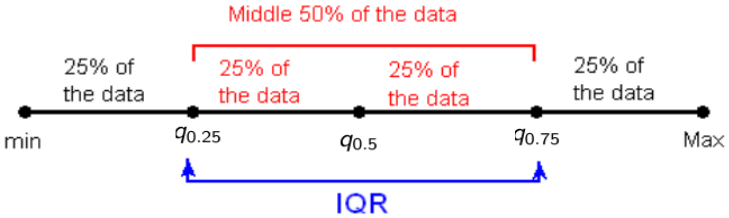

Pour obtenir ces statistiques, vous pouvez utiliser la fonction *quantile* ou *summary*

```
> quantile(x)

  0%  25%  50%  75% 100%
17.9 19.1 20.4 23.5 26.2
```

```
> summary(x)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
17.9	19.1	20.4	21.4	23.4	26.2

Calculant ce résumé pour la variable *Ozone* de l'exemple de la qualité de l'air:

```
> summary(airquality$Ozone)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.	NA's
1	18	31.5	42.1	63.2	168	37

L'avantage de la fonction *summary* c'est qu'on peut l'appliquer aussi sur un data-frame pour obtenir les statistiques de toutes les variables. Voici un exemple

```
> summary(airquality)
```

Ozone	Solar.R	Wind	Temp	Month	Day
Min. : 1.0	Min. : 7	Min. : 1.70	Min. :56.0	5:31	Min. : 1.0
1st Qu.: 18.0	1st Qu.:116	1st Qu.: 7.40	1st Qu.:72.0	6:30	1st Qu.: 8.0
Median : 31.5	Median :205	Median : 9.70	Median :79.0	7:31	Median :16.0
Mean : 42.1	Mean :186	Mean : 9.96	Mean :77.9	8:31	Mean :15.8
3rd Qu.: 63.2	3rd Qu.:259	3rd Qu.:11.50	3rd Qu.:85.0	9:30	3rd Qu.:23.0
Max. :168.0	Max. :334	Max. :20.70	Max. :97.0		Max. :31.0
NA's :37	NA's :7				

Et si nous souhaitons obtenir un summary de la variable *Ozone* pour chaque mois? La solution la plus simple consiste à écrire:

```
> aggregate(Ozone ~ Month, data = airquality, FUN = summary)

  Month Ozone.Min. Ozone.1st Qu. Ozone.Median Ozone.Mean Ozone.3rd Qu.
1     5        1.0          11.0         18.0       23.6          31.5
2     6       12.0          20.0         23.0       29.4          37.0
3     7        7.0          36.2         60.0       59.1          79.8
4     8        9.0          28.8         52.0       60.0          82.5
5     9        7.0          16.0         23.0       31.4          36.0
  Ozone.Max.
1      115.0
2       71.0
3      135.0
4      168.0
5       96.0
```

il s'agit d'exécuter la fonction *summary* sur la variable Ozone pour chaque groupe définit par la variable Month.

Le diagramme en boîte

Le diagramme en boîte (en anglais boxplot) ou boîte à moustache est une simple représentation graphique du résumé à cinq nombres dont le principe est décrit par le schéma suivant :

- une boîte du premier quartile au troisième quartile
- une ligne à la hauteur de la médiane
- les lignes (moustaches) qui vont des extrémités de la boîte aux points extrêmes se trouvant dans l'intervalle $[Q_1 - 1.5 \times IQR, Q_3 + 1.5 \times IQR]$.
- les observations classées comme atypiques (outliers). C'est tous les points en dehors des moustaches.

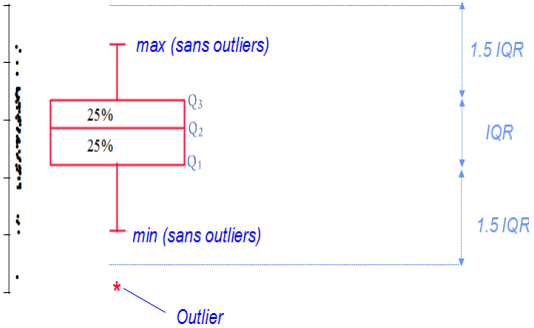

Boxplot avec R

```
> ggplot(airquality) +
  aes(x="", y = Temp) +
  geom_boxplot()
```

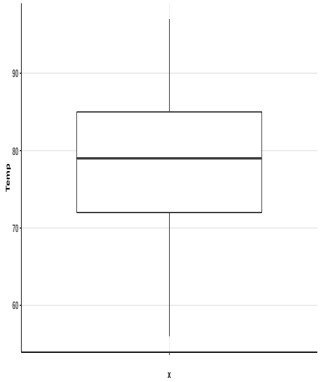


```
> ggplot(airquality) +
  aes(x=Month, y = Temp) +
  geom_boxplot()
```

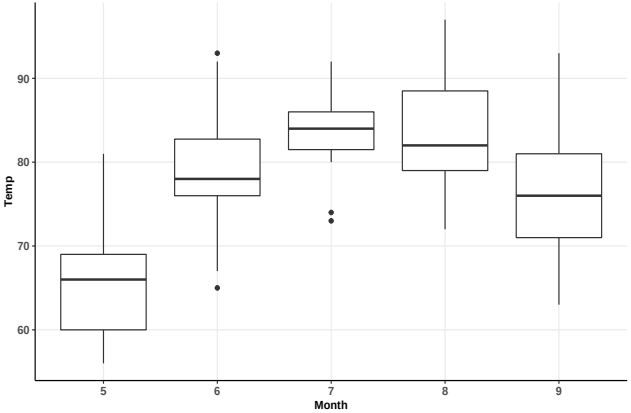

Exercice

Faites correspondre chaque histogramme à la boîte à moustaches qui représente le même ensemble de données.

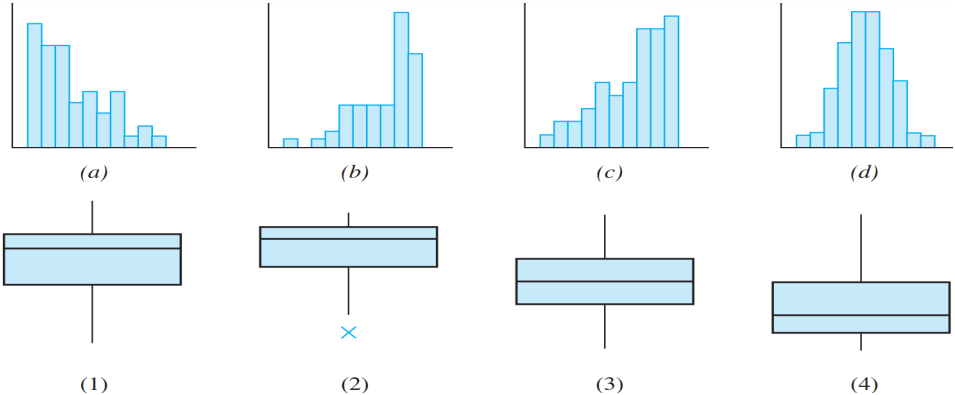

Description des données numériques

Indicateurs de dispersion

Pour exprimer les caractéristiques d'un échantillon, il est nécessaire de compléter les indicateurs de localisation par des indicateurs de dispersion, qui mesureront la variabilité des données.

Two samples of cholesterol measurements on a given person using the Autoanalyzer and Microenzymatic measurement methods

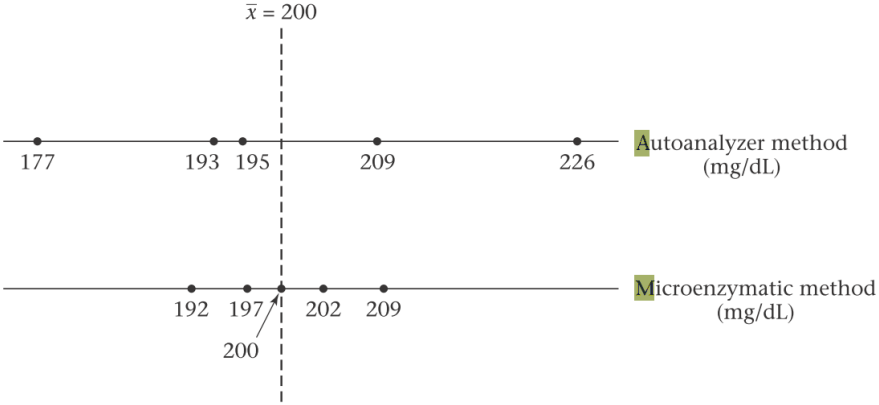

L'**ÉTENDUE** d'un échantillon est l'écart entre ces valeurs extrêmes, autrement dit c'est $\max(x_1, \ldots, x_n) - \min(x_1, \ldots, x_n)$

Pour la méthode A:

```
> A <- c(177, 193, 195, 209, 226)
> max(A) - min(A)
```

```
[1] 49
```

Pour la méthode M:

```
> M <- c(192, 197, 202, 209)
> max(M) - min(M)
```

```
[1] 17
```

L'**ÉCART INTERQUANTILE** (IQR) d'un échantillon est l'écart entre sont troisième et son premier quartile, autrement dit $IQR = Q_3 - Q_1$.

Pour la méthode A:

```
> IQR(A)
```

```
[1] 16
```

Pour la méthode M:

```
> IQR(M)
```

```
[1] 8
```

Variance et écart-type empiriques

La variance, notée par s_n^2, de n observations est la somme des carrés des écarts à la moyenne divisée par $n-1$.

$$s_n^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

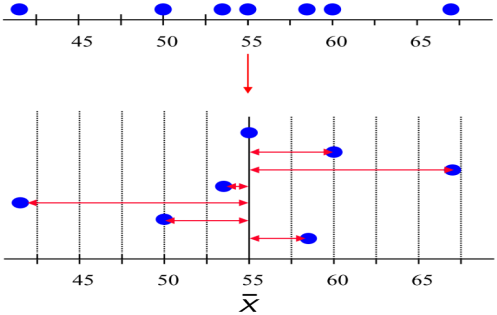

Pour la méthode A:

```
> var(A)

[1] 340
```

Pour la méthode M:

```
> var(M)

[1] 52.7
```

Il est facile de vérifier que

$$s_n^2 = \frac{1}{n-1}\left(\sum_i x_i^2 - n\bar{x}^2\right)$$

L'écart-type (standard deviation ou sd) est la racine carrée de la variance

$$s_n = \sqrt{s_n^2}$$

Il s'exprime dans la même unité que les données, ce qui rend son interprétation plus facile que celle de la variance.

L'écart-type quantifie la distance entre les observations et leur moyenne. Autrement dit, l'écart-type mesure la dispersion des données autour de leur moyenne.

Pour la méthode A:

```
> sd(A)
```

```
[1] 18.4
```

Pour la méthode M:

```
> sd(M)
```

```
[1] 7.26
```

Ce qui exprime bien la différence de variabilité des mesures entre les deux méthodes. La méthode A a un écart-type presque trois fois plus grand que celui de la méthode M. On peut dire que cette dernière est trois fois plus précise.

Notez que l'écart-type se laisse aussi influencer par les valeurs aberrantes :

```
> x <- c(12, 12, 13, 13, 13, 13, 13, 14, 14)
> y <- c(12, 12, 13, 13, 13, 13, 13, 14, 14, 24)
```

```
> sd(x)
```

```
[1] 0.707
```

```
> sd(y)
```

```
[1] 3.54
```

Règle empirique (dite des 68 — 95 — 99.7)

Une autre façon utile pour interpréter les valeurs d'un écart type est la règle empirique qui dit que pour beaucoup de jeux de données, la majorité (95%) des valeurs d'échantillon sont éloignées de moins de deux écarts types de la moyenne. Plus précisément, pour des données avec une distribution raisonnablement symétrique et sans valeurs aberrantes:

- Environ 68% des valeurs sont situées à moins d'un écart type de la moyenne (c-à-d entre $\bar{x} - s_n$ et $\bar{x} + s_n$);
- Environ 95% des valeurs sont situées à moins de deux écarts types de la moyenne ($\bar{x} - 2s_n$ et $\bar{x} + 2s_n$);
- Environ 99.7% des valeurs sont situées à moins de trois écarts types de la moyenne ($\bar{x} - 3s_n$ et $\bar{x} + 3s_n$).

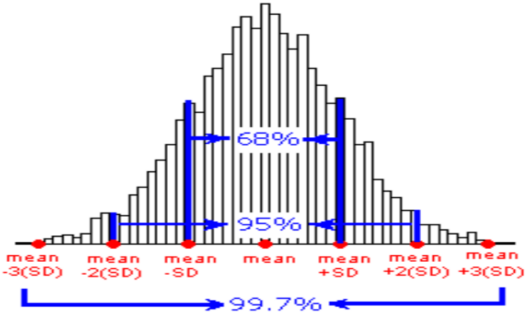

Quelques propriétés

Supposons qu'on observe $x_1 \ldots, x_n$. Soit $y_i = a + bx_i$, $i = 1, \ldots, n$, alors

$$\bar{y} = a + b\bar{x}, \quad s_y^2 = b^2 s_x^2, \quad s_y = |b| s_x$$

Exemple. La moyenne et l'écart-type de la variable *Temp* du data *airquality* sont 77.882 (^oF, degree Fahrenheit) et 9.465 (^oF), respectivement. Sachant que

$$T_C = (T_F - 32) \times \frac{5}{9}$$

On déduit que, en Celsius, la moyenne et l'écart-type sont

```
> c((77.882 - 32) * (5/9), 9.465 * (5/9))
```

```
[1] 25.49  5.26
```

Un inconvénient de l'écart-type en tant que mesure de variation est qu'elle dépend de l'unité de mesure.

Aussi, l'interprétation de l'écart-type dépend de la magnitude des données. En effet, un écart-type de 10° n'a pas le même sens si la température moyenne de référence est 12° ou 10000°. Les données présentent une forte variabilité si l'écart-type est grand par rapport à la moyenne.

On ne peut comparer la variation de deux ensembles de données que s'ils sont mesurés en même unité et qu'ils sont approximativement la même moyenne.

Coefficient de variation empirique

Le coefficient de variation, donné par $cv_x = \frac{s_x}{\bar{x}}$, est une mesure de dispersion relative. Ce nombre, sans unité, peut être utilisé pour comparer deux (ou plusieurs) séries de données d'unités et/ou de moyennes différentes.

Excercice. Supposons qu'on observe $x_1 \ldots, x_n$. Soit $y_i = bx_i$, $i = 1, \ldots, n$, avec $b > 0$. Montrez que $cv_x = cv_y$.

Exemple. Voici quelques statistiques obtenues sur deux échantillons correspondants à deux méthodes de mesures différentes.

	moyenne	écart-type	cv
Méthode A	38.3	3.13	0.082
Méthode B	95.9	5.28	0.055

La comparaison de l'écart-type (uniquement) peut entraîner une fausse conclusion. La méthode B est, vraisemblablement, plus précise que la méthode A.

Description des données numériques

Relations entre deux variables numériques

On s'intéresse à deux variables mesurées sur les n unités d'observation. Pour chaque unité, on obtient donc deux mesures. La série statistique est alors une suite de n couples des valeurs prises par les deux variables sur chaque individu :

$$(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)$$

La meilleure façon d'avoir une idée de la relation entre ces deux varaibles est de regarder un diagramme de dispersion (Scatterplot).

Les diagrammes de dispersion sont utiles pour comprendre

- la forme, la tendance générale,
- la direction, et la force d'association

entre deux variables.

Voici quelques exemples.

```
> ggplot(airquality) +
  aes(x = Solar.R, y = Ozone) +
  geom_point()
```

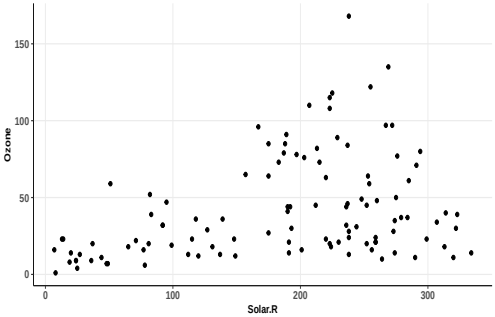


```
> ggplot(airquality) +
  aes(x = Wind, y = Ozone) +
  geom_point()
```

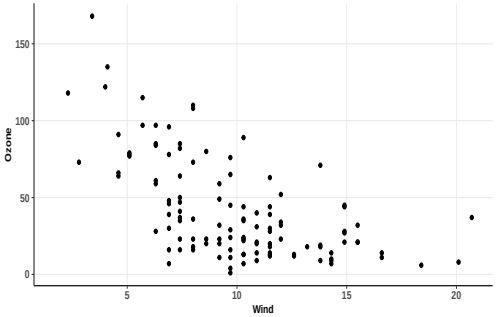

Que peut-on dire sur la relation entre Ozone et Solar.R ? Et entre Ozone et Wind ?

```
> ... + facet_wrap(Month ~ .)
```

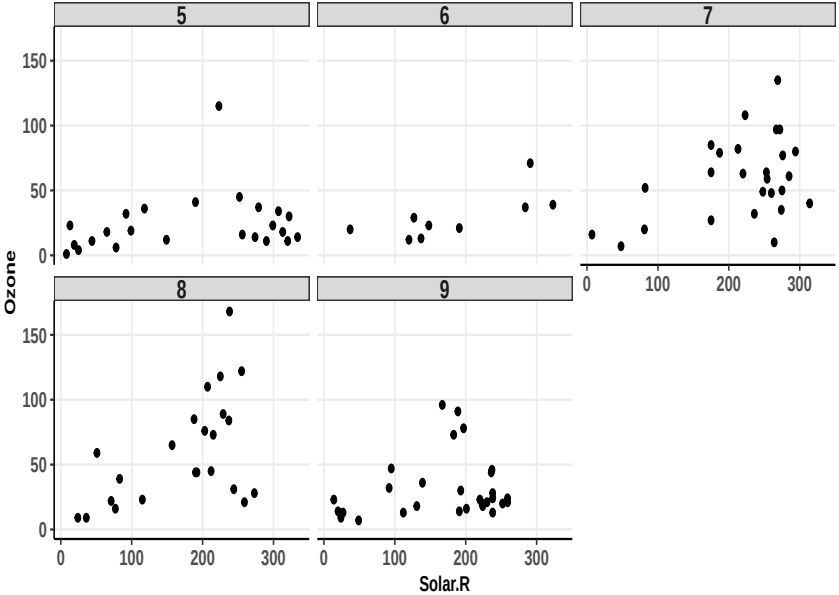

```
> ggplot(airquality) +
  aes(x = Solar.R, y = Ozone, color=Month) +
  geom_point()
```

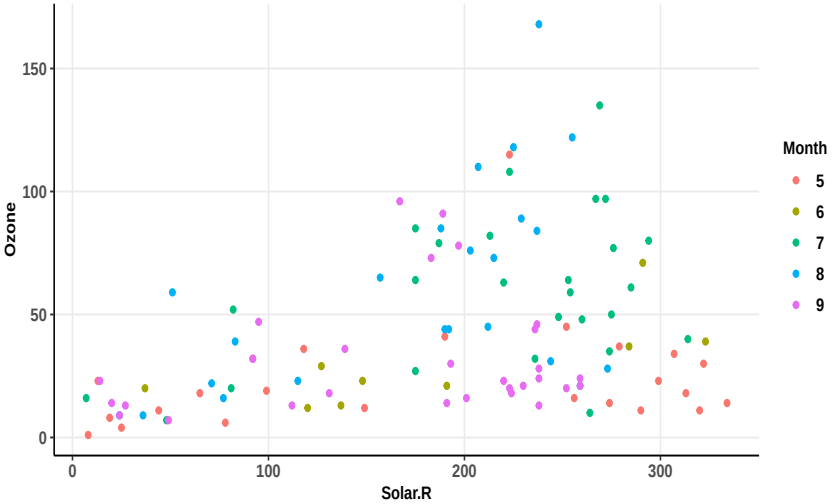

Fonctions R les plus utiles vues dans ce chapitre

- table, xtabs et prop.table
- cut, transform et aggregate
- mean, quantile, var, sd et summary
- ggplot et barplot